Projet TARDIS: Prédire les Retards de Train

Par Naim Mohamed, Rugema Epiphane, Abdelkader Ait Benamara

EPITECH - Piscine Data/IA

Made with GAMMA

Problématique & Objectifs

Le projet TARDIS vise à transformer des données brutes de la SNCF en informations exploitables pour optimiser la ponctualité ferroviaire.

Analyse Approfondie

Comprendre les causes profondes et les motifs récurrents des retards de train.

Prédiction Intelligente

Développer un modèle de régression pour estimer le retard moyen à l'arrivée.

Dashboard Interactif

Proposer une interface intuitive avec Streamlit pour visualiser et prédire.

Le Dataset SNCF: Aperçu des Données Clés

Notre analyse s'appuie sur un dataset riche en informations sur le trafic ferroviaire.

- **Date & Service:** Identification unique du trajet.
- **Stations Départ/Arrivée:** Origine et destination du train.
- **Durée Moyenne Trajet:** Temps de parcours théorique.
- **Volumes:** Circulations prévues.
- **Annulations:** Nombre d'annulations.
- **Retards Départ/Arrivée:** Minutes de retard au départ et à l'arrivée.
- **Retards > 15/30/60 min:** Indicateurs de retards majeurs.
- **Causes de Retard:** Répartition en % (infrastructure, trafic, matériel, etc.).
- **Year & Month:** Informations temporelles.

Objectif du modèle: Prédire le "Retard moyen de tous les trains à l'arrivée" (en minutes).

Pipeline de Projet: De la Donnée au Dashboard

Notre approche Data Science de bout en bout suit une série d'étapes structurées pour garantir la qualité et la pertinence des résultats.

Ce pipeline garantit une transformation efficace des données brutes en informations prédictives et interactives.

Nettoyage des Données: La Fondation d'une Analyse Fiable

Une étape cruciale pour assurer la qualité et la cohérence de notre dataset, indispensable pour la modélisation.

Gestion des Valeurs Manquantes

Traitement des "nan" textuels et des valeurs manquantes critiques (Date, Service, Stations).

Suppression des Doublons

Identification et élimination des enregistrements dupliqués basés sur la date et la paire de stations.

Standardisation des Formats

Cohérence du format des dates et gestion des noms de colonnes FR/EN.

Agrégation & Filtrage

Optimisation du dataset pour la modélisation.

Exploration des Données (EDA): Découverte d'Insights

L'EDA nous a permis de visualiser les tendances et les patterns cachés dans les retards de train.

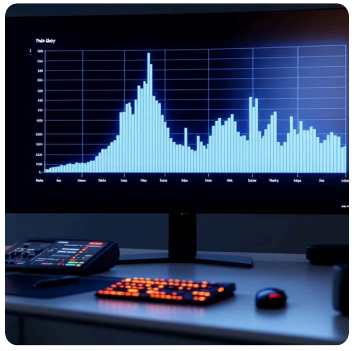

Distribution des Retards

Majorité des trains à l'heure ou avec de faibles retards, mais présence de pics significatifs.

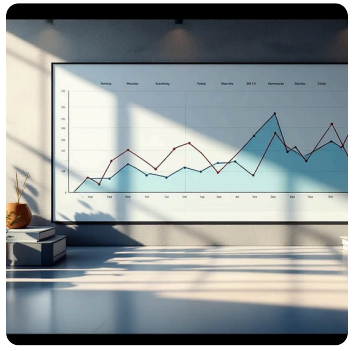

Évolution Mensuelle

Identification de variations saisonnières dans les retards, potentiellement liées aux conditions météorologiques ou périodes de vacances.

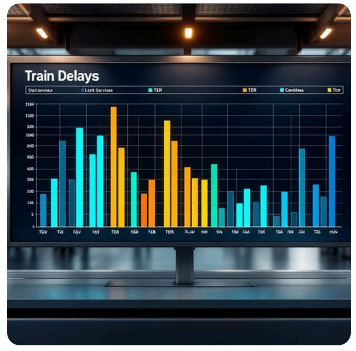

Comparaison par Service & Stations

Différences notables de ponctualité entre les types de service et les paires de stations.

Feature Engineering: Création de Variables Pertinentes

Nous avons enrichi notre dataset avec de nouvelles variables pour améliorer la performance du modèle.

- **Year & Month:** Extraction des informations temporelles pour capter la saisonnalité.
- **Gestion de la Date:** Création de variables comme le jour de la semaine ou le jour férié.
- **Agrégation:** Consolidation de données pour les paires de stations récurrentes.
- **Sélection des Variables:** Focus sur les features les plus influentes pour la prédiction interactive.

Ces variables sont essentielles pour capter les motifs complexes et les dépendances des retards.

Modélisation: Prédire le Retard Moyen

Nous avons mis en place une approche robuste pour prédire le retard moyen à l'arrivée des trains.

1

Baseline

Calcul du retard moyen simple pour établir un point de comparaison.

2

Modèle Final

RandomForestRegressor avec un pipeline intégré pour le prétraitement des données (imputation, OneHotEncoder, scaling).

3

Justification

Robustesse aux données bruitées, capacité à gérer les non-linéarités, et bonne intégration avec Streamlit.

Le modèle est exporté via `model.joblib` pour une intégration facile dans l'application.

Résultats de Modélisation: Évaluation des Performances

Comparaison des métriques de performance entre le modèle baseline et le RandomForestRegressor.

Baseline (Moyenne)

- MAE: 2.991 min
- RMSE: 4.392 min
- R^2: ≈ 0.000

La baseline montre l'absence de toute intelligence prédictive au-delà de la moyenne simple.

RandomForestRegressor

- MAE: 2.067 min
- RMSE: 4.293 min
- R^2: 0.045

Gain significatif de ~31% sur le MAE, malgré un R^2 faible indiquant des limites des features actuelles.

Ces résultats mettent en évidence l'amélioration apportée par le modèle, tout en soulignant la complexité du problème.

Dashboard Streamlit: Visualisation Interactive

L'application Streamlit offre une interface conviviale pour explorer les données et obtenir des prédictions.

Onglet Vue d'ensemble

Présentation des indicateurs clés (KPIs) et d'un histogramme de la distribution des retards.

Onglet Explorer

Filtres interactifs (service, départ/arrivée, périodes) et graphique dynamique pour une exploration approfondie.

Onglet Prédire

Formulaire simple pour estimer le retard moyen en minutes en sélectionnant le service et les stations.